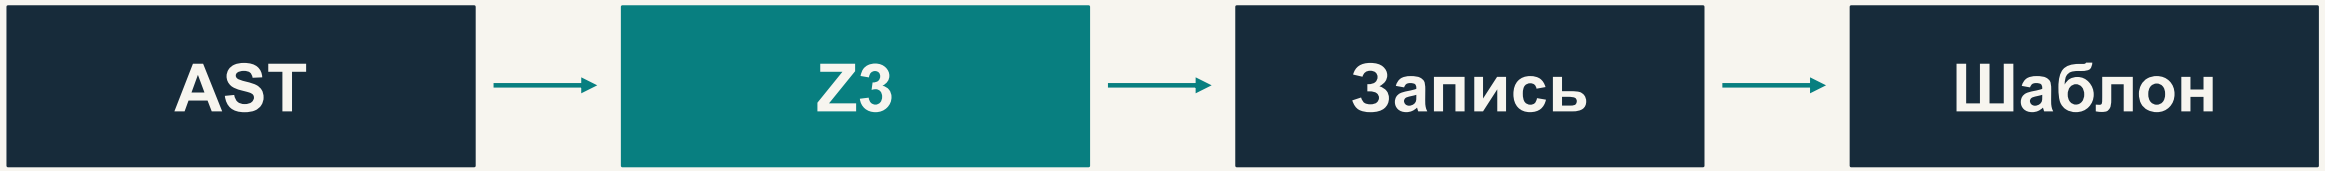
pytestgen

Гибридная генерация pytest-тестов

Аркадий Лебедев

МФТИ, материалы на 13 ноября 2026

Гибридный пайплайн



Функции и ветки | Входы и границы | Результат вызова | pytest-тест

LLM — Новые входы, проверка оракула, свободные тесты для сложного кода

Проверка — Запуск pytest, repair и поиск пробелов покрытия. На выходе: тесты и отчёт Markdown / JSON.

Без LLM остаются Z3 и граничные входы.

Архитектура и инженерные проверки



Адаптеры реализуют порты, домен хранит данные.

Запуск кода

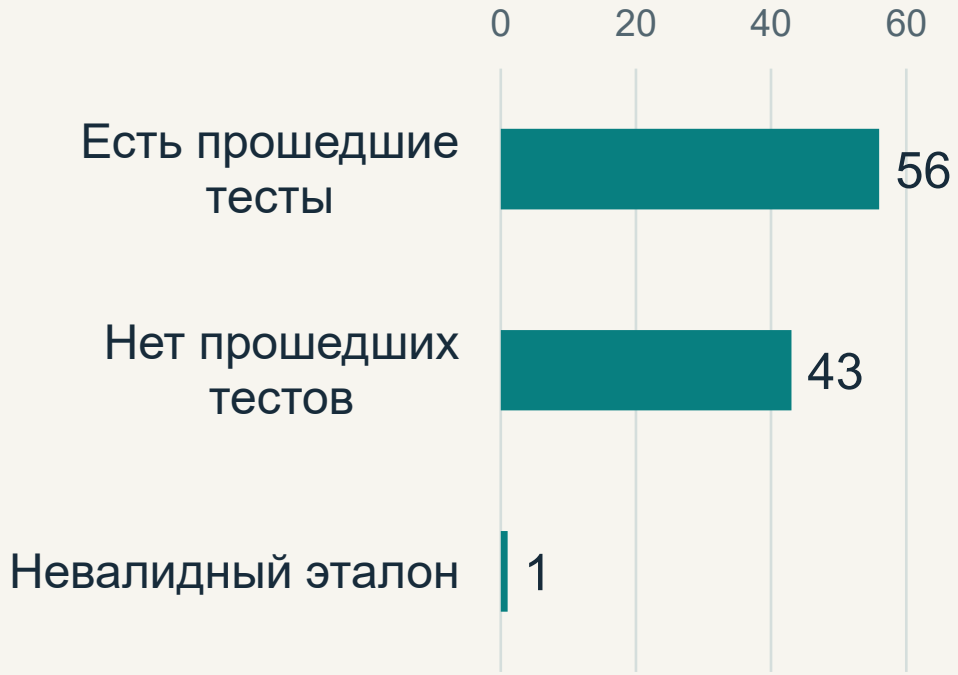
Временная копия, subprocess и таймауты.
Docker упаковывает приложение целиком.

Граница защиты

Нет отдельного контейнера на каждый тест.
Враждебный код требует более строгой изоляции.

CI: 1864 passed, 4 skipped, покрытие 98,60% (Python 3.12).

MBPP: результат на 100 задачах



Метрика	Число	Доля
Проходят эталон	352/353	99,7%
Проходят эталон и убивают мутанта	224/353	63,5%
Убитые мутанты	104/174	59,8%

Доли тестов условны: только 353 сохранённых.
4 запуска мутантов не проверены. 1 тест упал на эталоне.

Qwen2.5-Coder 1.5B, Q4_K_M, CPU

Проверка эвристики repair

8 × 2 × 2 = 32

Функции × docstring / без docstring × два типа ошибки

Сценарий	Что проверяем после repair
Мутант + корректный тест	Маскировку ошибки кода
Корректный код + ошибочный тест	Исправление ошибочного теста

Отдельно: 32 наблюдения для oracle review.

Арифметика, границы и исключения. Эвристику не подбираем по результатам.

Ошибки и ложные предупреждения

Repair

Истина	Сигнал	Нет сигнала
Маскировка	0 TP	1 FN
Исправление теста	5 FP	5 TN

Precision 0,0% Recall 0,0%

Oracle: рассмотренные случаи

Истина	Сигнал	Нет сигнала
Баг в коде	1 TP	7 FN
Корректный код	1 FP	7 TN

Precision 50,0% Recall 12,5%

Repair: 11/32 классифицированы, 21 не исправлены.
Все 8 случаев doc + bug без repair; recall группы не определён.
Oracle: 16/32 рассмотрены, 16 без docstring получили UNREVIEWED.

Проверка на python-slugify 8.0.4

slugify/slugify.py: slugify и smart_truncate

Набор	Пройдено	Строки	Ветви
Upstream (baseline)	82/82	85/92 (92,4%)	46/50 (92,0%)
Existing: только новые	13/13	72/92 (78,3%)	30/50 (60,0%)
Existing + upstream	95/95	86/92 (93,5%)	47/50 (94,0%)
Cold: только новые	18/18	72/92 (78,3%)	34/50 (68,0%)
Cold + upstream	100/100	86/92 (93,5%)	47/50 (94,0%)

Оба режима: +1 строка (+1,09 п.п.), +1 ветвь (+2,00 п.п.).

Исходники upstream-тестов не входят в промпт.

Выводы и живая демонстрация

Гибридный генератор работает с малой локальной LLM.

Проверяемость Тесты, покрытие и причины отбраковки сохраняются.

Ограничения Оракул может закрепить баг. Repair может его скрыть. Малые выборки ограничивают обобщение.

Демонстрация CLI

```
uv run pytestgen generate examples/shop/pricing.py
    --project-root examples -o out/test_pricing_generated.py
```